

Informatyka w medycynie
Wykrywanie naczyń dna oka

Jakub Pietrzak 136612
Jan Kozłowski 136743

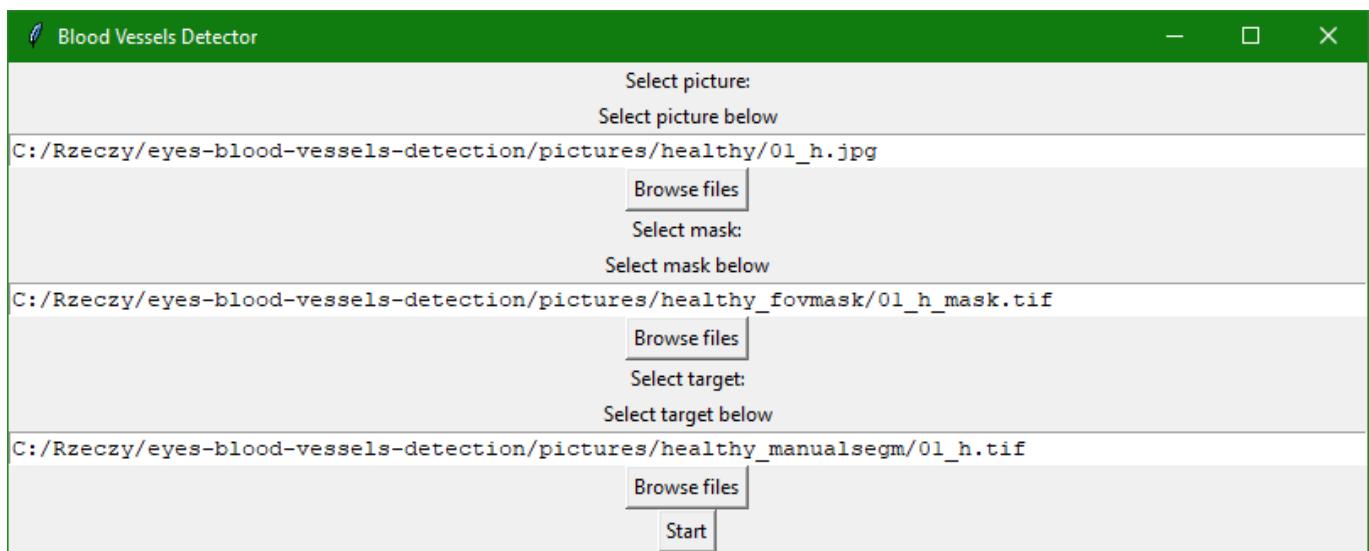
1. Skład grupy

Jakub Pietrzak 136612
Jan Kozłowski 136743

2. Język programowania i biblioteki

Zastosowany język programowania: Python Zastosowane biblioteki:

- numpy - obliczenia oraz proste przetwarzanie obrazu
- opencv - przetwarzanie obrazu
- tensorflow-gpu i keras - sieci neuronowe
- sklearn - k-krotna walidacja skrośna
- tkinter - interfejs

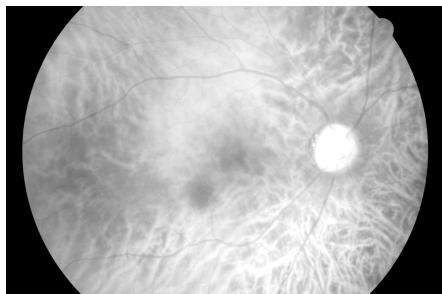


3. Zastosowane metody

3.1. Przetwarzanie obrazów

1. Wyciągnięcie z obrazu warstwy zielonej.
2. Zastosowanie filtra Gaussa w celu rozmazania obrazu i pozbycia się szumu.
3. Wykorzystanie progowania adaptacyjnego.

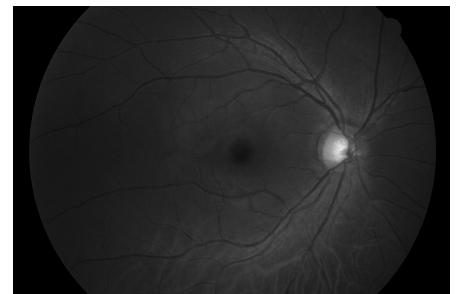
Wycięcie kanału niebieskiego, a szczególnie czerwonego sprawiło, że różnice w jasności między naczyniami krwionośnymi a pozostałą częścią oka stały się zdecydowanie bardziej widoczne. Tak przygotowany obraz został poddany działaniu filtru Gaussa, który usunął z niego ewentualny szum. Na takim obrazie zastosowano progowanie adaptacyjne. Jako że różnica w jasności między naczyniami krwionośnymi a pozostałą częścią oka była wystarczająco duża, progowanie dało bardzo dobry efekt końcowy.



Czerwona warstwa



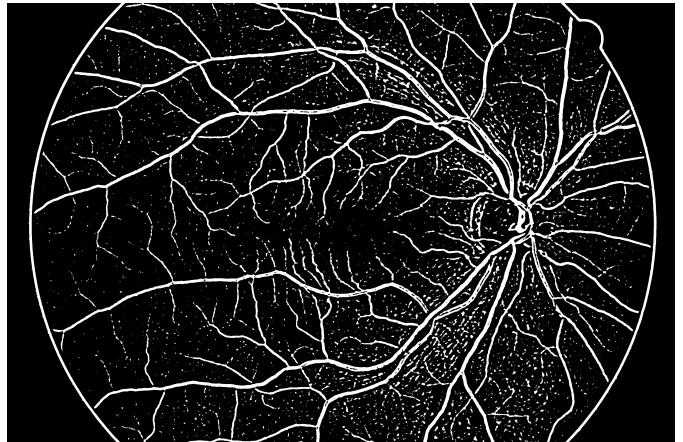
Zielona warstwa



Niebieska warstwa



Efekt zastosowania filtra Gaussa na warstwie zielonej



Efekt adaptacyjnego progowania

3.2. Uczenie maszynowe

1. Przygotowanie danych:

- I. Wycięcie ze środka wcześniej przetworzonego obrazu (kroki 1 i 2 przetwarzania obrazu) oraz maski eksperckiej kwadratu o rozmiarze 2048x2048.
- II. Wylosowanie piksela z wyciętego wcześniej fragmentu oraz sprawdzenie jego wartości.
- III. Wycięcie kwadratu wokół tego piksela oraz dodanie go do listy, dopóki liczba tak przygotowanych fragmentów nie będzie zawierała zadanej liczby fragmentów pozytywnych (wylosowany piksel w masce eksperckiej == 1) oraz negatywnych (wylosowany piksel w masce eksperckiej == 0).

2. Zastosowane metody uczenia maszynowego: Sieć neuronowa o następujących warstwach:

1. Conv2D
2. MaxPooling2D
3. Conv2D
4. MaxPooling2D
5. Conv2D
6. MaxPooling2D
7. Flatten
8. Dense
9. Dense

Na wejście sieci podawany jest fragment obrazu o wymiarach 65x65.

Do wykrywania naczyń krwionośnych zastosowaliśmy konwolucyjną sieć neuronową - CNN. Użyliśmy tego rodzaju sieci, gdyż radzą one sobie szczególnie dobrze w rozpoznawaniu i klasyfikacji obrazów. Nasza sieć składa się z trzech par warstw konwolucyjnych oraz następujących po nich warstw Poolingu. Zbiór tych warstw służy do wydobycia cech danego fragmentu (takich jak naczynia krwionośne). Następną warstwą jest Flatten, która spłaszcza dane tak, żeby były one dostępne dla kolejnych warstw - Dense. Warstwy te służą do klasyfikacji fragmentów obrazka na podstawie cech, które wcześniej zostały wydobyte przez warstwy konwolucyjne.

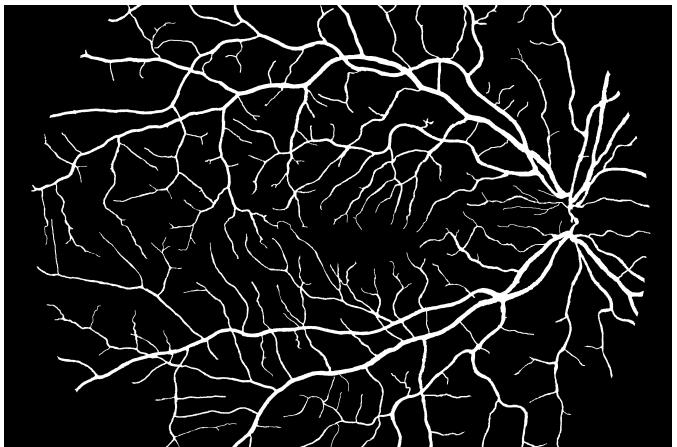
4. Wizualizacja i analiza wyników działania

Wykorzystane przez nas obrazy to obrazy zdrowego oka z bazy HRF. Do treningu sieci wykorzystane zostały fragmenty pierwszych 10 obrazów, a testom poddawaliśmy ostatnie 5.

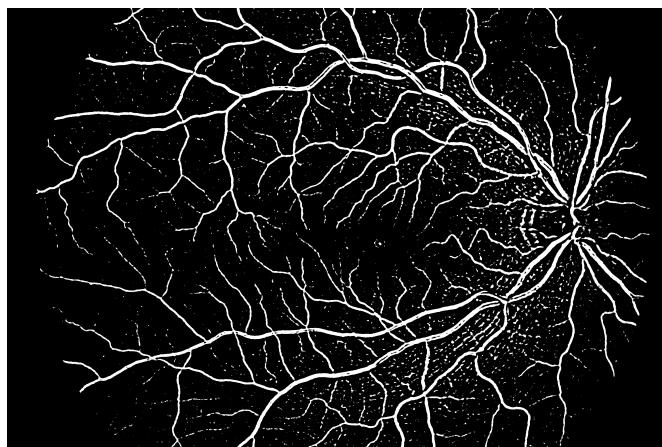
4.1. Obraz 11



Obraz 11



Maska ekspercka

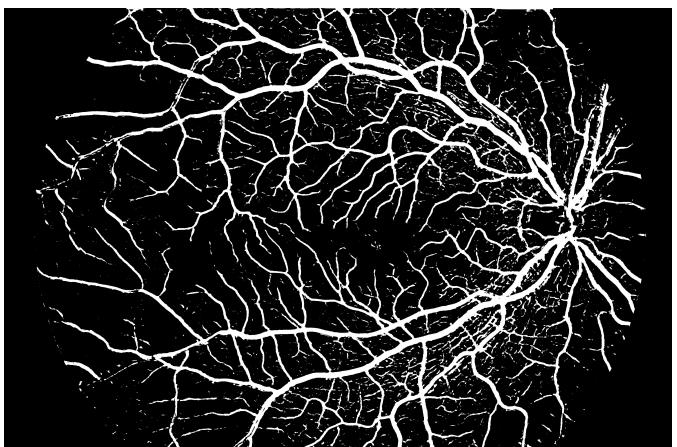


Przetwarzanie obrazu

Trafność: 0.959

Czułość: 0.767

Swoistość: 0.979



Uczenie maszynowe

Trafność: 0.932

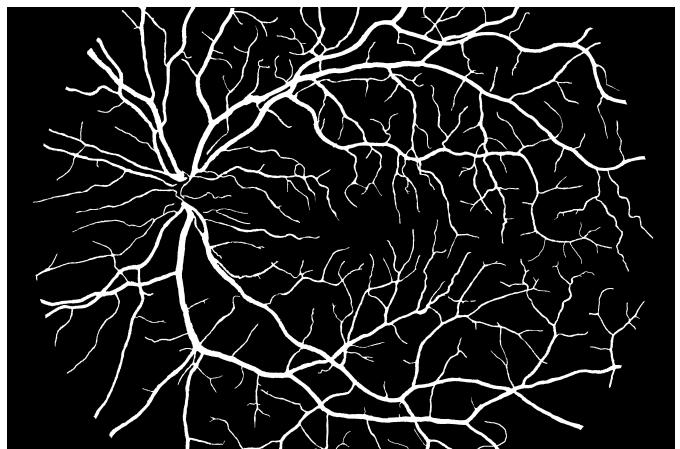
Czułość: 0.875

Swoistość: 0.938

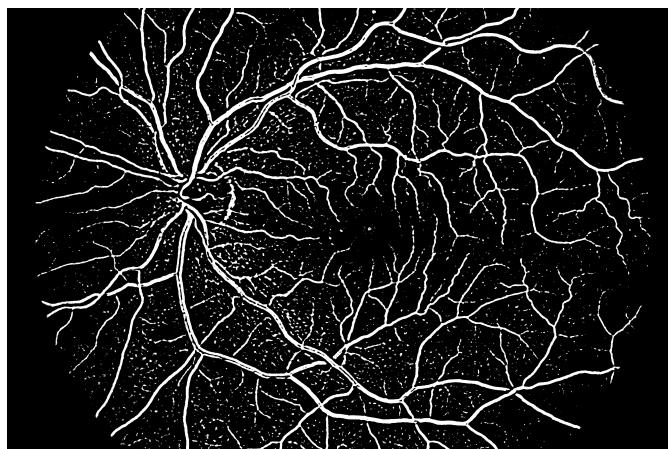
4.2. Obraz 12



Obraz 12



Maska ekspercka

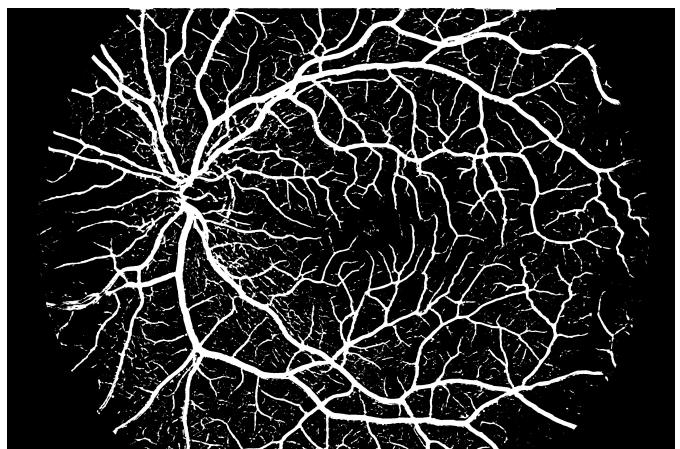


Przetwarzanie obrazu

Trafność: 0.952

Czułość: 0.777

Swoistość: 0.973



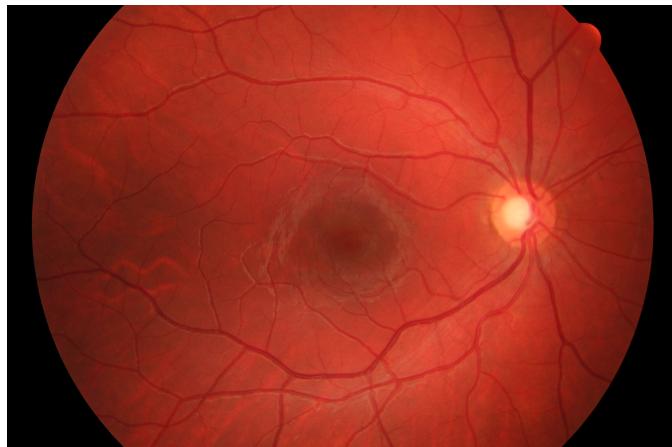
Uczenie maszynowe

Trafność: 0.931

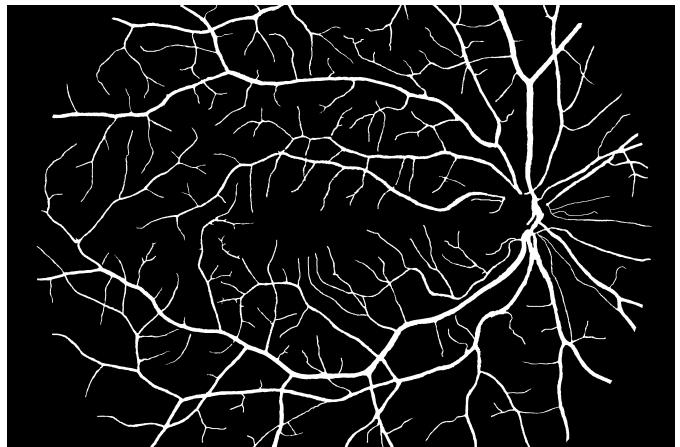
Czułość: 0.913

Swoistość: 0.933

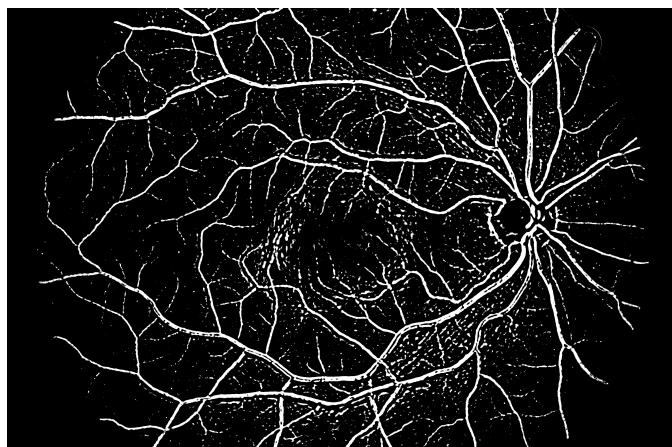
4.3. Obraz 13



Obraz 13



Maska ekspercka

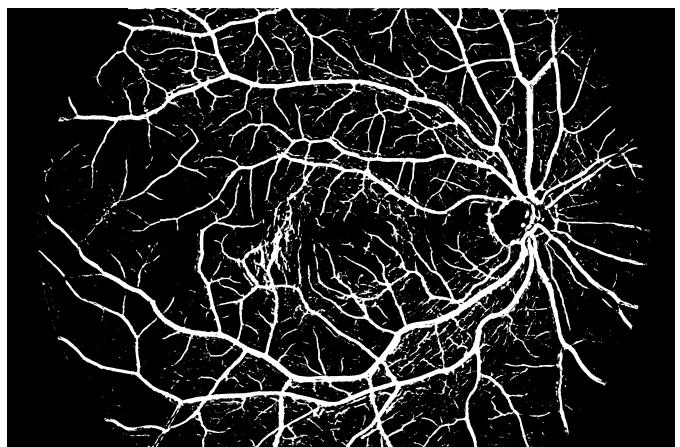


Przetwarzanie obrazu

Trafność: 0.949

Czułość: 0.734

Swoistość: 0.970



Uczenie maszynowe

Trafność: 0.928

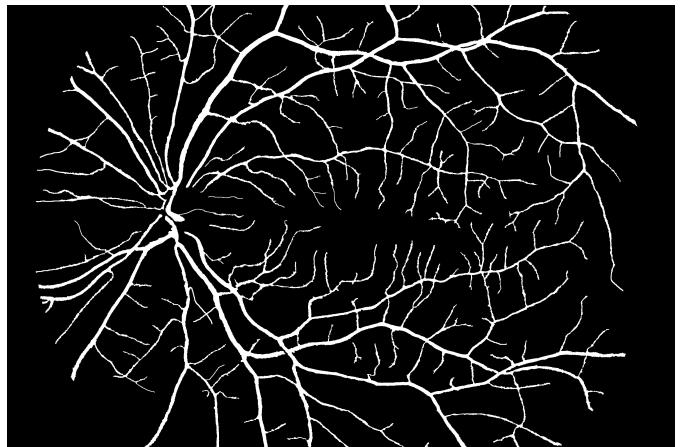
Czułość: 0.873

Swoistość: 0.934

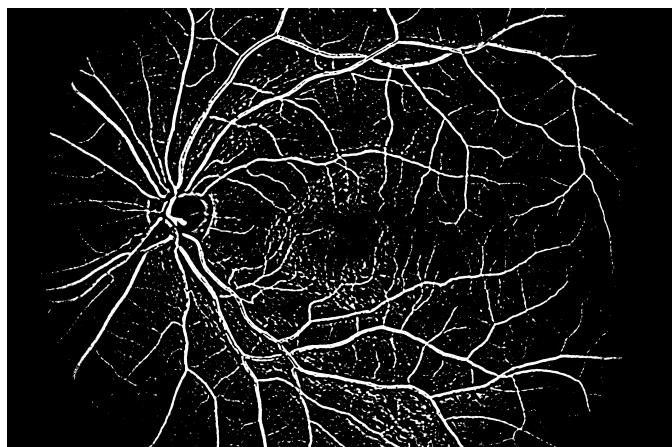
4.4. Obraz 14



Obraz 14



Maska ekspercka



Przetwarzanie obrazu

Trafność: 0.950

Czułość: 0.736

Swoistość: 0.971



Uczenie maszynowe

Trafność: 0.927

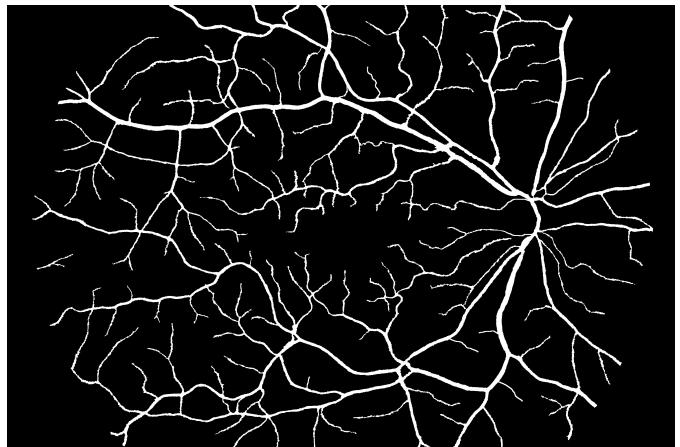
Czułość: 0.840

Swoistość: 0.935

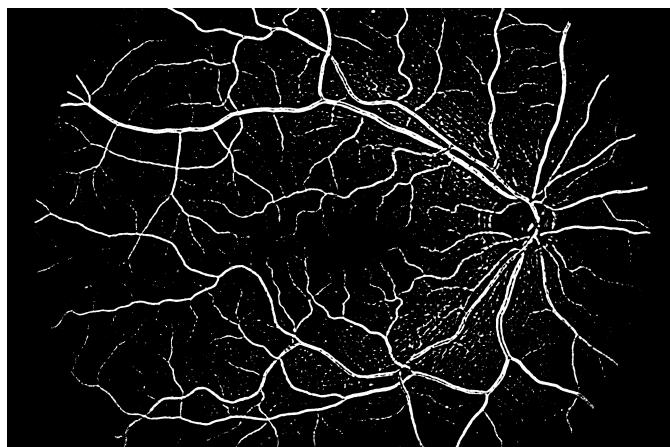
4.5. Obraz 15



Obraz 15



Maska ekspercka

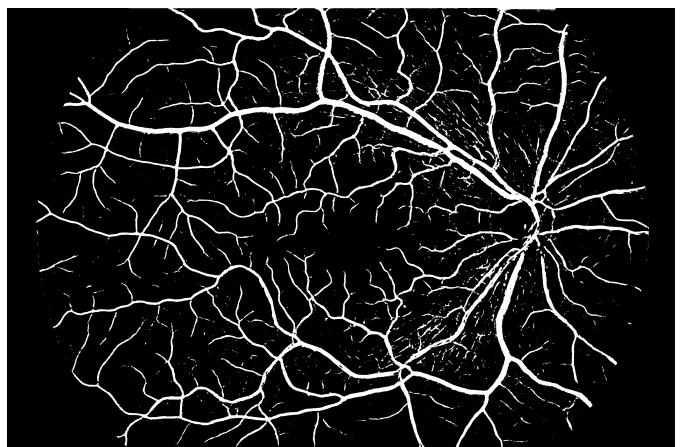


Przetwarzanie obrazu

Trafność: 0.963

Czułość: 0.727

Swoistość: 0.983



Uczenie maszynowe

Trafność: 0.959

Czułość: 0.875

Swoistość: 0.966

5. Podsumowanie

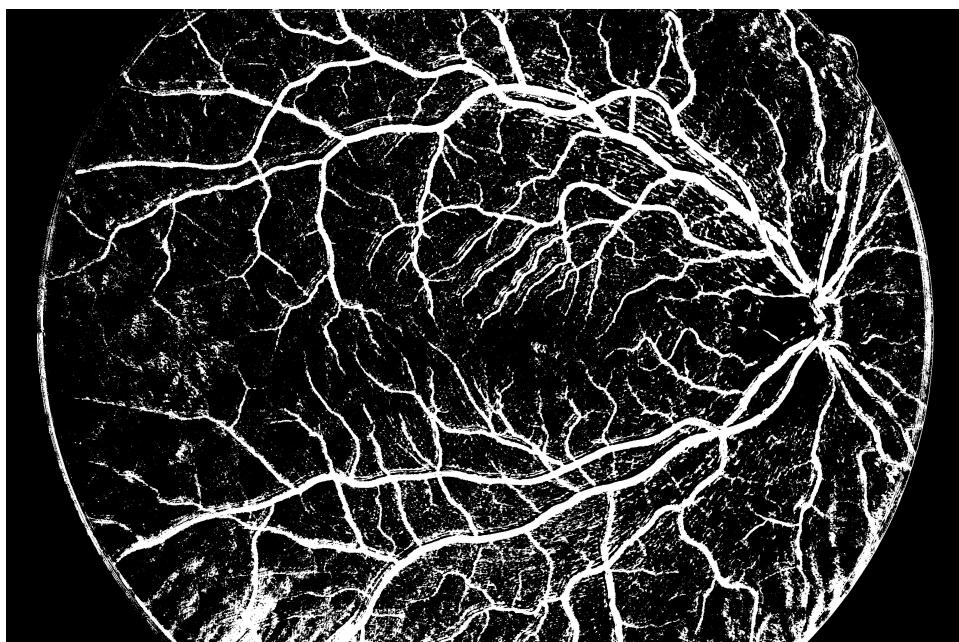
W poniższej tabelce zebrane zostały uśrednione pomiary:

Uśrednione wartości miar

	Przetwarzanie obrazu	Sieć neuronowa
Trafność	0.955	0.935
Czułość	0.748	0.875
Swoistość	0.975	0.941

Jak widać, nie udało nam się wytrenować sieci o wyższej trafności niż nasze podstawowe przetwarzanie obrazu. Można zauważać, że nasza sieć ma znacznie wyższą czułość (skok o około 0.13), jednak wiązało się to ze spadkiem swoistości - porównując obrazki zamieszczone wyżej można zauważać, że wiąże się on głównie z pogrubieniem naczyń w stosunku do maski eksperckiej.

Próbowaliśmy różnych wymiarów wycinków podawanych na wejście sieci, np. 33x33. Dzięki temu mogliśmy zwiększyć liczebność zbioru uczącego nie ryzykując brakiem pamięci - pozwoliło nam to między innymi na wytrenowanie sieci lepiej radzącej sobie z nerwem wzrokowym - przykład poniżej. Zmniejszenie rozmiaru wycinka powodowało jednak znaczne pogorsze ogólnego działania.



Znaczącym argumentem przemawiającym za podstawowym przetwarzaniem obrazu jest również czas przetwarzania - dla przetwarzania obrazu jest to czas znikomy, a dla sieci przetwarzanie jednego obrazu trwa od 13-18 minut przy użyciu karty graficznej NVIDIA GeForce RTX 2060 SUPER.